

IPRJ

Graduação em Engenharia de Computação
Tópicos Especiais em Matemática e Computação

Trabalho 3

Comparação de SVM e RFR com Otimização PSO

Nathália Viana de Carvalho

Dezembro 2025

1 Descrição dos Dados

A base de dados utilizada para o seguinte trabalho foi *Student Performance*, disponível no repositório UCI Machine Learning Repository. Essa base contém informações sobre estudantes do ensino médio em Portugal, com dados relativos às disciplinas de Matemática e Português. Trata-se de um problema de regressão, cujo objetivo é prever a nota final dos alunos (G3). Foram utilizadas duas bases, *student-mat.csv* e *student-por.csv*, que continham, respectivamente, 395 e 649 amostras. Após a união, a base final totalizou 1044 amostras e 33 atributos. Não há dados faltantes nem registros repetidos. Foram identificados outliers para alguns atributos conforme o boxplot abaixo (figura 1) dos atributos mais importantes de acordo com o método de seleção SelectKbest, implementado no primeiro trabalho.




Figura 1: Boxplot dos atributos da base *Student Performance*.

2 Pré-processamento

Na etapa de pré-processamento, não foi necessário o tratamento de valores faltantes, uma vez que a base não apresentou nenhum valor faltante. A base continha vários atributos qualitativos, foi aplicado o Label Encoding para transformar essas variáveis em quantitativas. A fim de padronizar os dados, o StandardScaler foi incorporado ao pipeline. Esta padronização foi necessária para a posterior aplicação do algoritmo de Máquina de Vetor Suporte, que é baseado em distância e, portanto, sensível à escala dos dados.

3 Análise dos Dados

Com o objetivo de analisar as correlações, foram calculadas as principais estatísticas dos atributos selecionados.

A partir da matriz de correlação (Figura 2), é possível observar que o desempenho escolar (G3) está fortemente correlacionado às notas intermediárias (G1 e G2).

Tabela 1: Estatísticas Descritivas dos Atributos Seleccionados

Métrica	school	age	Medu	Fedu	studytime	failures	higher	Dalc	G1	G2
Count	1044.00	1044.00	1044.00	1044.00	1044.00	1044.00	1044.00	1044.00	1044.00	1044.00
Mean	0.2605	16.7261	2.6034	2.3879	1.9703	0.2644	0.9148	1.4943	11.2136	11.2462
Std. Dev.	0.4391	1.2400	1.1249	1.0999	0.8344	0.6561	0.2794	0.9117	2.9834	3.2851
Variance	0.1928	1.5375	1.2654	1.2099	0.6961	0.4305	0.0781	0.8312	8.9006	10.7917
Min	0.00	15.00	0.00	0.00	1.00	0.00	0.00	1.00	0.00	0.00
25% (Q1)	0.00	16.00	2.00	1.00	1.00	0.00	1.00	1.00	9.00	9.00
50% (Mediana)	0.00	17.00	3.00	2.00	2.00	0.00	1.00	1.00	11.00	11.00
75% (Q3)	1.00	18.00	4.00	3.00	2.00	0.00	1.00	2.00	13.00	13.00
Max	1.00	22.00	4.00	4.00	4.00	3.00	1.00	5.00	19.00	19.00




Figura 2: Matriz de correlação dos principais atributos incluindo a variável alvo(G3).

4 Metodologia

Neste trabalho, foi feita uma comparação entre dois algoritmos de aprendizado de máquina aplicados a um problema de regressão. O primeiro método aplicado foi a Máquina de Vetor Suporte, com hiperparâmetros otimizados pelo PSO. O segundo método foi o Random Forest. Para ambos os algoritmos foram avaliados os dados originais da base *Student Performance* e os dados pré-processados e normalizados por *standardscale* e seleção de características.

Os dados foram divididos utilizando *holdaout* com 80% para treinamento e 20% para teste. Foi aplicada a validação cruzada K-fold com 10 folds. Cada experimento foi executado 30 vezes e a média e o desvio padrão das métricas de desempenho foram calculadas.

Tabela 2: Configuração experimental do trabalho

Parâmetro	Valor
Base de dados	Student Performance
Tamanho do teste (Holdout)	20%
K-Fold	10 dobras
Número de execuções	30
Meta-heurística	PSO
Modelos avaliados	SVM e RFR
Métricas	R^2 , MAE, MSE

O algoritmo de otimização PSO foi configurado com os parâmetros: $c1 = 1.5$, $c2 = 1.5$ e $w = 0.6$. Para o modelo SVM os limites de busca foram $[0.1, 1000]$ para o hiperparâmetro c e $[0.0001, 1]$ para o hiperparâmetro γ . Para o modelo RFR os limites foram: $[10, 500]$ para $n_estimators$, $[1, 100]$ para max_depth e $[2, 50]$ para min_sample_splits .

As métricas de avaliação utilizadas para avaliar o desempenho dos modelos foram:

- Coeficiente de determinação (R^2): calcula qual a porcentagem da variância que pôde ser prevista pelo modelo de regressão e, portanto, nos diz o quão “próximo” as medidas reais estão do modelo.
- Erro Absoluto Médio (MAE): consiste na média das distâncias entre valores preditos e reais.
- Erro Quadrático médio (MSE): consiste na média do erro das previsões ao quadrado.

Para verificar se as diferenças entre os modelos treinados com os dados pré-processados e originais são estatisticamente significativas, foi aplicado o teste de Wilcoxon com $\alpha = 0,05$.

5 Resultados

Os resultados obtidos com 30 execuções utilizando a otimização por PSO e validação cruzada de 10 folds estão na tabela a seguir.

Tabela 3: Resultados da Validação Cruzada (Média $\pm$ Desvio Padrão)

Configuração	$R^2 (\mu \pm \sigma)$	MAE ($\mu \pm \sigma$)	MSE ($\mu \pm \sigma$)
RFR Original	0.8566 ± 0.0024	0.8967 ± 0.0075	2.1404 ± 0.0362
RFR Pré-Processado	0.8254 ± 0.0025	0.9713 ± 0.0136	2.6059 ± 0.0368
SVM Original	0.8329 ± 0.0033	0.8899 ± 0.0314	2.4939 ± 0.0488
SVM Pré-Processado	0.8273 ± 0.0003	0.8639 ± 0.0036	2.5772 ± 0.0043

A Tabela 3 fornece a média e desvio padrão das métricas para as quatro configurações testadas: dados originais e pré-processados, aplicados ao SVM e RFR. O melhor desempenho foi do modelo Random Forest Regressor, utilizando os dados originais, alcançando um R^2 médio de 0.8566 ± 0.0024 e o menor erro quadrático médio (MSE) de 2.1404 ± 0.0362 . Já o modelo de Support Vector Machine obteve o melhor erro absoluto (MAE) de 0.8639 ± 0.0036 , utilizando os dados pré-processados.

Para o modelo RFB, a aplicação do pré-processamento levou a uma queda de desempenho. Os modelos finais, treinados com a melhor configuração de hiperparâmetros foram avaliados no

conjunto teste de 20% e os resultados obtidos estão na Tabela 4 e os melhores hiperparâmetros encontram-se na tabela 5.

Tabela 4: Resultados de Desempenho no Conjunto de Teste (Holdout)

Métrica	SVM Original	SVM Pré-Processado	RFR Original	RFR Pré-Processado
R²	0.8054	0.8022	0.8227	0.7801
MAE	1.0292	0.9023	0.9280	1.0444

Tabela 5: Melhores Hiperparâmetros Encontrados nas Execuções de Maior Desempenho (Holdout)

Modelo/Configuração	Hiperparâmetro	Valor Ótimo	Métrica de Referência (Holdout)
RFR Original	n_estimators	333	Maior R ² (0.8227)
	max_depth	46	
	min_samples_split	23	
SVM Pré-Processado	C	341.67	Menor MAE (0.9023)
	γ	0.0001	

No conjunto de teste, o RFR com dados originais continuou sendo o modelo com melhor desempenho e o SVM com dados pré-processados manteve o menor MAE. O teste de Wilcoxon foi aplicado para determinar se a diferença de desempenho entre os dados originais e pré-processados é estatisticamente significativa. Os resultados do teste estão presentes na Tabela 6.

Tabela 6: Resultados do Teste de Wilcoxon

Comparação	P-Valor	Conclusão ($\alpha = 0.05$)
SVM (Original vs. Pré-Processado)	1.86×10^{-9}	Diferença Estatisticamente Significativa
RFR (Original vs. Pré-Processado)	1.86×10^{-9}	Diferença Estatisticamente Significativa

O p-valor obtido em ambas as comparações é bem menor que o $\alpha = 0.05$, logo, pode-se concluir que o pré-processamento gerou uma mudança estatisticamente significativa na distribuição dos resultados dos dois modelos.

6 Conclusão

Neste trabalho, foi comparado o desempenho dos modelos Support Vector Machine (SVM) e Random Forest Regressor (RFR) para resolver o problema de regressão da base de dados Student Performance.

O melhor desempenho geral (R²) foi do RFR com dados originais, este foi o modelo que demonstrou ser o mais eficaz para explicar a variância dos dados, obtendo maior R² tanto no K-fold quanto no holdout. Além disso, obteve também o menor (MSE) no K-fold.

O modelo SVM com dados pré-processados obteve o menor (MAE) nas duas etapas de avaliação. O teste de Wilcoxon mostrou que o pré-processamento causou uma diferença estatisticamente significativa nos resultados de ambos os modelos, obtendo um p-valor de 1.86×10^{-9} nas duas comparações.

Referências

CORTEZ, P.; SILVA, A. M. G. **Student Performance Data Set**. UCI Machine Learning Repository, 2014. Disponível em: <https://archive.ics.uci.edu/dataset/320/student+performance>. Acesso em: 09 out. 2025.